

30/4/2024

# Μοντέλα Αξιοπιστίας και Επιβίωσης

ΣΕΙΡΑ 2

Κοντοθανάση Σωτηρία  
ΑΜ: 09120080

**(Α) Γράψτε τη λογαριθμοποιημένη συνάρτηση πιθανοφάνειας για το μοντέλο της Λογαριθμο-κανονικής κατανομής όταν έχουμε δεξιά αποκομμένες παρατηρήσεις.**

Γνωρίζουμε ότι η σππ της Λογαριθμο-κανονικής δίνεται από τον τύπο:

$$f(t) = \frac{1}{\sigma t \sqrt{2\pi}} \exp\left(\frac{-(\ln t - \mu)^2}{2\sigma^2}\right), \quad t > 0$$

Γνωρίζουμε ότι η συνάρτηση επιβίωσης της Λογαριθμο-κανονικής δίνεται από τον τύπο:

$$S(t) = 1 - \Phi\left(\frac{\ln t - \mu}{\sigma}\right)$$

Επιπλέον γνωρίζουμε ότι για αποκομμένες παρατηρήσεις ισχύει :

$$L = \prod_{i \in U} f(t_i) \prod_{i \in C} S(t_i) = \prod_i \{f(t_i)^{\delta_i} S(t_i)^{1-\delta_i}\}$$

Επομένως έχουμε ότι :

$$L = \prod_{i \in U} \left\{ \frac{1}{\sigma t \sqrt{2\pi}} \exp\left(\frac{-(\ln t - \mu)^2}{2\sigma^2}\right) \right\} \prod_{i \in C} \left\{ 1 - \Phi\left(\frac{\ln t - \mu}{\sigma}\right) \right\}$$

και

$$\begin{aligned} \ell = \ln(L) &= \sum_{i \in U} \ln \left\{ \frac{1}{\sigma t \sqrt{2\pi}} e^{\left(\frac{-(\ln t - \mu)^2}{2\sigma^2}\right)} \right\} \sum_{i \in C} \ln \left\{ 1 - \Phi\left(\frac{\ln t - \mu}{\sigma}\right) \right\} \\ &= \sum_{i \in U} \left\{ \ln\left(\frac{1}{\sigma t \sqrt{2\pi}}\right) + \frac{-(\ln t - \mu)^2}{2\sigma^2} \right\} \sum_{i \in C} \ln \left\{ 1 - \Phi\left(\frac{\ln t - \mu}{\sigma}\right) \right\} \\ &= \sum_{i \in U} \left\{ -\ln(\sigma t \sqrt{2\pi}) + \frac{-(\ln t - \mu)^2}{2\sigma^2} \right\} + \sum_{i \in C} \ln \left\{ 1 - \Phi\left(\frac{\ln t - \mu}{\sigma}\right) \right\} \\ &= -k \ln(\sigma t \sqrt{2\pi}) + k \frac{-(\ln t - \mu)^2}{2\sigma^2} + \sum_{i \in C} \ln \left\{ 1 - \Phi\left(\frac{\ln t - \mu}{\sigma}\right) \right\} \end{aligned}$$

όπου  $k$  το πλήθος των τιμών χωρίς αποκοπή .

(B) Ο παρακάτω πίνακας δίνει τη διάρκεια ζωής (σε ημέρες) 20 εξαρτημάτων, μετά από συνεχή χρήση.

725	838	853	965	1139	1142	1304	1317	1427
1658	1764	1776	1990	2010	2224	2244*	2279*	2286*

( \*=δεξιά αποκομμένες παρατηρήσεις)

i. Να βρεθούν οι εκτιμήσεις Kaplan–Meier και να γίνει η γραφική παράσταση αυτών.

Εισαγωγή των δεδομένων στην R :

```
> cmdat <-  
read.table("C:\\Users\\Admin\\Desktop\\8οΕΞΑΜΗΝΟ\\data-  
seira2ExB.txt", header = TRUE)
```

```
> attach(cmdat)
```

The following object is masked from cmdat (pos = 3):

t

The following object is masked from cmdat (pos = 4):

t

The following object is masked from cmdat (pos = 5):

t

The following objects are masked from cmdat (pos = 6):

censor, t


```
> cmdat
```

```
      t censor  
1    468      1  
2    725      1  
3    838      1  
4    853      1  
5    965      1  
6   1139      1  
7   1142      1  
8   1304      1  
9   1317      1  
10  1427      1  
11  1554      1  
12  1658      1  
13  1764      1  
14  1776      1  
15  1990      1  
16  2010      1  
17  2224      1  
18  2244      0  
19  2279      0  
20  2286      0
```

```
> outp<-survfit(Surv(t, censor)~1)
> summary(outp)
Call: survfit(formula = Surv(t, censor) ~ 1)
```

time	n.risk	n.event	survival	std.err	lower	95% CI	upper	95% CI
468	20	1	0.95	0.0487		0.8591		1.000
725	19	1	0.90	0.0671		0.7777		1.000
838	18	1	0.85	0.0798		0.7071		1.000
853	17	1	0.80	0.0894		0.6426		0.996
965	16	1	0.75	0.0968		0.5823		0.966
1139	15	1	0.70	0.1025		0.5254		0.933
1142	14	1	0.65	0.1067		0.4712		0.897
1304	13	1	0.60	0.1095		0.4195		0.858
1317	12	1	0.55	0.1112		0.3700		0.818
1427	11	1	0.50	0.1118		0.3226		0.775
1554	10	1	0.45	0.1112		0.2772		0.731
1658	9	1	0.40	0.1095		0.2339		0.684
1764	8	1	0.35	0.1067		0.1926		0.636
1776	7	1	0.30	0.1025		0.1536		0.586
1990	6	1	0.25	0.0968		0.1170		0.534
2010	5	1	0.20	0.0894		0.0832		0.481
2224	4	1	0.15	0.0798		0.0528		0.426

```
> plot(outp, main=expression(paste("Kaplan-Meier-estimate ",
hat(S) (t))),
+ conf.int=FALSE,xlab="t", ylab="Survival")
```



### **Παρατηρήσεις:**

Παρατηρώ ότι όσο ο χρόνος περνάει , όλο και λιγότερες μονάδες βρίσκονται σε κίνδυνο. Επιπλέον παρατηρώ ότι με την πάροδο του χρόνου όλο και περισσότερες μονάδες αποτυγχάνουν – χαλάνε (failed).

Όσον αφορά την γραφική παράσταση της Kaplan – Meier, η οποία εκτιμά με μη παραμετρικό τρόπο την συνάρτηση επιβίωσης , παρατηρώ ότι τα σκαλάκια δεν πέφτουν απότομα προς τα κάτω αλλά είναι πιο εξαπλώμενα, που σημαίνει ότι τα γεγονότα δεν συμβαίνουν γρηγορα στην πάροδο του χρόνου. Έχω δηλαδή ένα φαινομενο που εξιλεσσεται αργα με την πάροδο του χρόνου.

- ii. Κάνοντας χρήση των εκτιμήσεων Kaplan–Meier  $\hat{S}(t_i)$  να γίνουν γραφικοί έλεγχοι για τις κατανομές: Εκθετική, Weibull, Λογαριθμο–κανονική και Λογαριθμο–λογιστική.

Εξετάζω αν τα δεδομένα μου ακολουθούν την Εκθετική Κατανομή.

Αρχικά βρίσκω τη λίστα των εκτιμημένων πιθανοτήτων επιβίωσης με χρήση της Kaplan - Meier για κάθε χρονικό σημείο όπως έχω υπολογίσει προηγούμενος.

```
> outp$surv
[1] 0.95 0.90 0.85 0.80 0.75 0.70 0.65 0.60 0.55 0.50 0.45 0.40
0.35 0.30 0.25
[16] 0.20 0.15 0.15 0.15 0.15
```

Έπειτα βρίσκω τις εκτιμημένες πιθανότητες επιβίωσης με χρήση της Kaplan - Meier μόνο για τα χρονικά σημεία όπου συνέβη ένα συμβάν (δηλαδή **n.event == 1**).

```
> SKM<-outp$surv [outp$n.event ==1]
> SKM
[1] 0.95 0.90 0.85 0.80 0.75 0.70 0.65 0.60 0.55 0.50 0.45 0.40
0.35 0.30 0.25
[16] 0.20 0.15
```

Υστερα βρίσκω τα χρονικά σημεία κατά τα οποία συνέβη ένα συμβάν (δηλαδή **n.event == 1**).

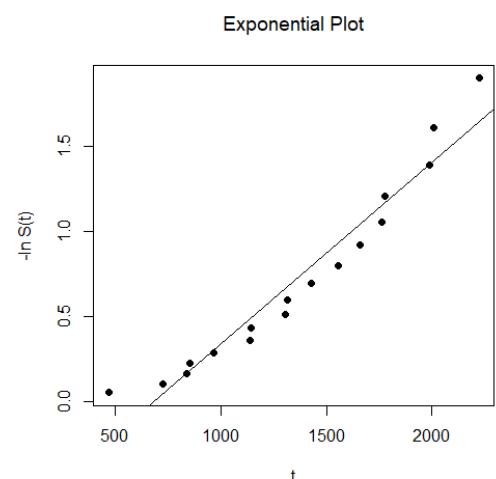
```
> Utime<-outp$time[outp$n.event ==1]
> Utime
[1] 468 725 838 853 965 1139 1142 1304 1317 1427 1554 1658
1764 1776 1990
[16] 2010 2224
```

Τελος , κάνοντας χρήση των εκτιμήσεων της Kaplan Meier και με κατασκευή του παρακάτω γραφήματος θα δω εάν τα δεδομένα του πειραματος μας, για τα οποία συνέβη το γεγονός ακολουθούν το μοντέλο της Εκθετικής Κατανομής.

```
> ##Examine whether data follows Exponential distribution
>
> plot(Utime,-log(SKM), main=expression(paste("Exponential
Plot")), xlab="t",
+ ylab="-ln S(t)", pch=19)
> abline(lm(-log(SKM)~Utime))
```

### Συμπέρασμα :

Σύμφωνα με το διαγράμμα στα δεξιά, λόγω μικρής τάυτισης των αποτελεσμάτων(εκτιμήσεων KM) με την ευθεία έχω αρκετές ενδείξεις ώστε να απορρίψω την υποθήση , ότι τα δεδομένα ακολουθούν το μοντέλο της Εκθετικής Κατανομής.



Εξετάζω αν τα δεδομένα μου ακολουθούν την Κατανομή Weibull .

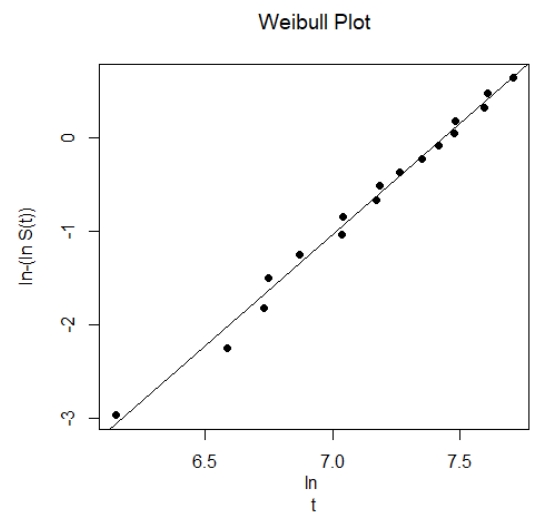
Σε αυτήν την περίπτωση, κάνοντας χρήση των εκτιμήσεων της Kaplan Meier και με κατασκευή του παρακάτω γραφήματος θα δω εάν τα δεδομένα του πειράματος μας, για τα οποία συνέβη το γεγονός ακολουθούν το μοντέλο της Κατανομής Weibull .

```
> ##Examine whether data follows Weibull distribution
>
> plot(log(Utime),log(-log(SKM)), main=expression(paste("Weibull
Plot")), xlab="ln
+ t", ylab="ln-(ln S(t))", pch=19)
> abline(lm(log(-log(SKM))~log(Utime)))
```

### **Συμπέρασμα :**

Σύμφωνα με το διαγγραμμα στα δεξιά, λόγω μεγάλης τάυτισης των αποτελεσμάτων(εκτιμήσεων KM) με την ευθεία δεν έχω αρκετές ενδείξεις ώστε να απορρίψω την υποθέση , ότι τα δεδομένα ακολουθούν το μοντέλο της κατανομή Weibull.

Σε αντιθεση με τον προηγουμενο έλεγχο, όπου είχα αρκετες ενδείξεις ώστε να απόρριψω την Εκθετική Κατανομή.



Εξετάζω αν τα δεδομένα μου ακολουθούν την Κατανομή LogNormal.


Σε αυτήν την περίπτωση, κάνοντας χρήση των εκτιμήσεων της Kaplan Meier και με κατασκευή του παρακάτω γραφήματος θα δω εάν τα δεδομένα του πειραματός μας, για τα οποία συνέβη το γεγονός ακολουθούν το μοντέλο της Κατονομης LogNormal .

```
> ##Examine whether data follows LogNormal distribution
>
> norm_quant<-qnorm(1-SKM,0,1)
> norm_quant
[1] -1.6448536 -1.2815516 -1.0364334 -0.8416212 -0.6744898 -
0.5244005
[7] -0.3853205 -0.2533471 -0.1256613 0.0000000 0.1256613
0.2533471
[13] 0.3853205 0.5244005 0.6744898 0.8416212 1.0364334
> plot(log(Utime), norm_quant, pch=19)
> abline(lm(norm_quant ~ log(Utime)))
```

### Συμπέρασμα :

Σύμφωνα με το διαγγραμμα στα δεξιά, λόγω μεγάλης τάνυσης των αποτελεσμάτων(εκτιμήσεων KM) με την ευθεία δεν έχω αρκετές ενδείξεις ώστε να απορρίψω την υποθέση , ότι τα δεδομένα ακολουθούν το μοντέλο της κατανομή Log Normal.

Άρα βρισκόμαστε σε ένα σημείο όπου τα δεδομένα του πειραματός θα μπορούσαν να ακολουθούν και το μοντέλο της Weibull και το μοντέλο της LogNormal . Ωστόσο φαίνεται τα δεδομένα μου να έχουν κατά ελάχιστα μεγαλύτερη τάνυση με την ευθεία στο μοντέλο της Weibull και μικρότερη τάνυση με την ευθεία στο μοντέλο της LogNormal.





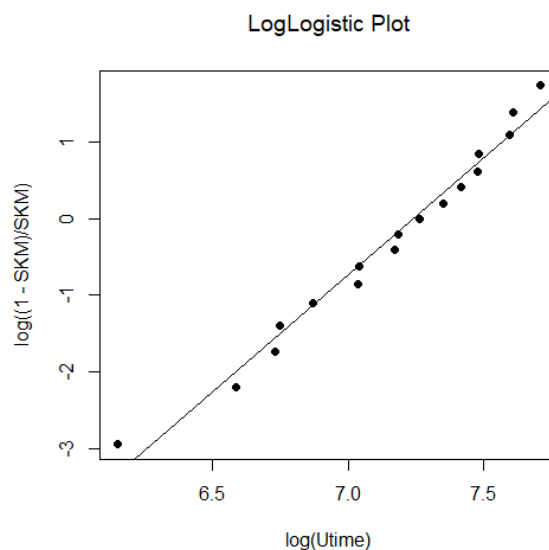
Εξετάζω αν τα δεδομένα μου ακολουθούν την Κατανομή LogLogistic

```
> ##Examine whether data follows LogLogistic distribution
>
> plot(log(Utime), log((1-SKM)/SKM), pch=19,,
main=expression(paste("LogLogistic Plot")))
> abline(lm(log((1-SKM)/SKM) ~ log(Utime)))
>
```

### **Συμπέρασμα :**

Σύμφωνα με το διαγγραμμα στα δεξιά, λόγω μεγάλης τάυτισης των αποτελεσμάτων(εκτιμήσεων KM) με την ευθεία δεν έχω αρκετές ενδείξεις ώστε να απορριψω την υποθέση , ότι τα δεδομένα ακολουθούν το μοντέλο της κατανομή Log Logistic.

Επομένως βρισκόμαστε σε ένα σημείο όπου τα δεδομένα του πειράματος θα μπορούσαν να ακολουθούν και το μοντέλο της Weibull και το μοντέλο της Log Normal και το μοντέλο της Log Logistic. Ωστόσο φαίνεται τα δεδομένα μου να έχουν κατά ελάχιστα μεγαλύτερη ταύτιση με την ευθεία στο μοντέλο της Weibull και μικρότερη ταύτιση με την ευθεία στο μοντέλο της Log Normal και της Log Logistic.



- iii. Στη συνέχεια προσαρμόστε στα δεδομένα, τα παραπάνω τέσσερα μοντέλα κατανομών με τη μέθοδο μέγιστης πιθανοφάνειας (ML) και κατασκευάστε γραφικές παραστάσεις των  $\hat{S}(t_i; \hat{\theta}) - ML$  με τα σημεία  $\hat{S}(t_i) - Kaplan - Meier$  για τις κατανομές αυτές.

Για την προσαρμογή των παρακάτω μοντέλων θα χρησιμοποιήσουμε από τα δεδομένα τον χρόνο επιβίωσης, δηλαδή τις ημέρες όπου κατάφεραν και δούλεψαν/λειτουργήσαν τα εξαρτήματα και το ποιες παρατηρήσεις ήταν δεξιά αποκομμένες και ποιες όχι, δηλαδή ποια και πόσα εξαρτήματα χάλασαν, σε ποια χρονική στιγμή και εξαρτήματα συνέχισαν να δουλεύουν.

### Εκθετική Κατανομή

Πάμε αρχικά να προσαρμόσουμε το μοντέλο της Εκθετικής Κατανομής

```
> mod1<-survreg(Surv(t, censor)~1, data=cmdat, dist="exponential")  
> mod1
```

Call:

```
survreg(formula = Surv(t, censor) ~ 1, data = cmdat, dist =  
"exponential")
```

Coefficients:

(Intercept)

**7.474505**

Scale fixed at 1

```
Loglik(model)= -144.1   Loglik(intercept only)= -144.1  
n= 20
```

Παραπάνω δίνεται μία εκτίμηση της παραμέτρου  $\alpha$  μέσω της μεθόδου μέγιστης πιθανοφάνειας.

### Συμπέρασμα :

1. Συντελεστής **Intercept**: Ο εκτιμηθείς συντελεστής Intercept είναι περίπου 7.4745. Ο συντελεστής Intercept για την εκθετική κατανομή αναπαριστά το λογάριθμο της αναμενόμενης επιβίωσης για τον παράμετρο κλίμακας (scale parameter) της κατανομής.
2. Κλίμακα: Η κλίμακα είναι προσδιορισμένη στην τιμή 1. Αυτό σημαίνει ότι η αναλλοίωτη κλίμακα της εκθετικής κατανομής έχει οριστεί ως 1.
3. Λογαριθμική Πιθανοφάνεια (Log Likelihood): Η λογαριθμική πιθανοφάνεια για το μοντέλο είναι περίπου -144.1, ενώ η λογαριθμική πιθανοφάνεια για ένα μοντέλο που περιλαμβάνει μόνο τη σταθερά Intercept είναι επίσης περίπου -144.1. Αυτό υποδηλώνει ότι η προσθήκη οποιασδήποτε άλλης μεταβλητής στο μοντέλο δεν βελτιώνει την προσαρμογή του.

Με βάση αυτά τα αποτελέσματα, μπορούμε να συμπεράνουμε ότι η εκθετική κατανομή φαίνεται να είναι μια καλή προσαρμογή στα δεδομένα σας, αλλά δεν υπάρχει αρκετή ενδεικτική διακύμανση στις παρατηρήσεις για να βελτιώσει το μοντέλο.

## Κατανομή Weibull

Τώρα προσαρμόζουμε το μοντέλο της Κατανομής Weibull.

```
>modweib<-fit_data(data = cdat, dist = "weibull", time = "t",
  censor = "censor")
> summary(modweib)
Fitting of the distribution ' weibull ' By maximum likelihood on
censored data
Parameters
      estimate  Std. Error
shape    2.576253    0.5226988
scale 1752.966512 166.4985523
Loglikelihood: -136.6462  AIC:  277.2924  BIC:  279.2839
Correlation matrix:
      shape    scale
shape 1.000000 0.129957
scale 0.129957 1.000000
```

### Συμπέρασμα :

#### **1. Παράμετροι Κατανομής Weibull:**

Η εκτιμηθείσα τιμή του παραμέτρου shape είναι περίπου 2.576253, που υποδηλώνει το σχήμα της κατανομής Weibull. Μια τιμή του shape μεγαλύτερη από 1 υποδεικνύει μια καμπύλη πιθανοφάνειας που αυξάνεται, ενώ μια τιμή μικρότερη από 1 υποδεικνύει μια καμπύλη πιθανοφάνειας που μειώνεται.

Η εκτιμηθείσα τιμή της παραμέτρου scale είναι περίπου 1752.966512, που αντιστοιχεί στην κλίμακα της κατανομής Weibull. Η κλίμακα καθορίζει το χρονικό διάστημα στο οποίο παρατηρούνται οι συμβάντα.

**2. Παράμετροι Εκτίμησης:** Η τυπική απόκλιση (Std. Error) για την εκτίμηση του shape είναι περίπου 0.5226988 και για την εκτίμηση της κλίμακας είναι περίπου 166.4985523.

#### **3. Στατιστικά Κριτήρια:**

Η λογαριθμική πιθανοφάνεια (Loglikelihood) για το μοντέλο είναι περίπου -136.6462.

Το AIC είναι περίπου 277.2924.

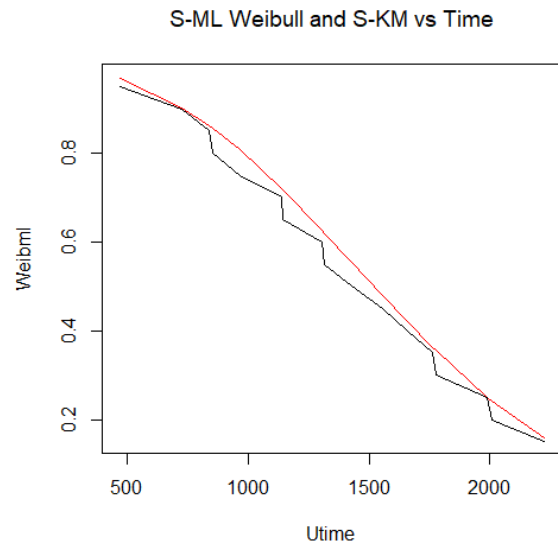
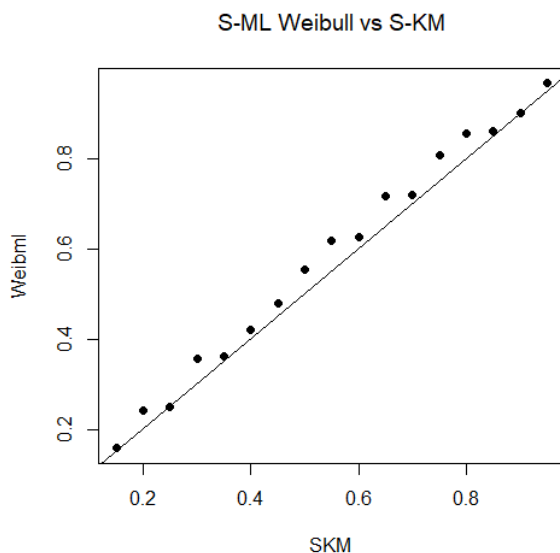
Το BIC είναι περίπου 279.2839.

**4. Συσχέτιση Παραμέτρων:** Η συσχέτιση μεταξύ των παραμέτρων shape και scale είναι περίπου 0.129957. Αυτό υποδεικνύει το επίπεδο της συσχέτισης μεταξύ των δύο παραμέτρων.

Συνολικά, τα αποτελέσματα αυτά δείχνουν ότι η κατανομή Weibull προσαρμόζεται καλά στα δεδομένα σας, με τις εκτιμηθείσες παραμέτρους να παρέχουν μια καλή περιγραφή της καμπύλης επιβίωσης.

Στη συνέχεια , θα προχωρήσω στην κατασκευή γραφικής παράστασης S-ML vs S-KM.

```
> #1.
> outp<-survfit(Surv(t,censor)~1)
> SKM<-outp$surv [outp$n.event ==1]
> SKM
[1] 0.95 0.90 0.85 0.80 0.75 0.70 0.65 0.60 0.55 0.50 0.45 0.40
0.35 0.30 0.25
[16] 0.20 0.15
>
> Utime<-outp$time[outp$n.event ==1]
> Utime
[1] 468 725 838 853 965 1139 1142 1304 1317 1427 1554 1658
1764 1776 1990
[16] 2010 2224
>
>
> #2.
> Weibml<- pweibull(Utime, shape= modweib$estimate[1], scale =
modweib$estimate[2],
+ lower.tail = FALSE, log.p = FALSE)
> Weibml
[1] 0.9672481 0.9022690 0.8612589 0.8552638 0.8066701 0.7194243
0.7178152
[8] 0.6271194 0.6195902 0.5551095 0.4803845 0.4204924 0.3619331
0.3555097
[15] 0.2499656 0.2410829 0.1578320
>
> #3.
> plot(Weibml~SKM, pch=19, main=expression(paste("S-ML Weibull vs
S-KM"))))
> abline(0,1)
>
> plot(Weibml~Utime,type="l",col="red", main=expression(paste("S-
ML Weibull and S-KM vs Time")))
> lines(SKM~Utime,col="black")
```



### Παρατηρήσεις:

Με το κόκκινο χρώμα στο παραπάνω γράφημα είναι η κατανομή Weibull ενώ με μαύρο χρώμα είναι οι εκτιμήσεις με την Μέθοδο Μεγίστης Πιθανοφάνειας . Παρατηρούμε λοιπόν ότι η κατανομή Weibull προσαρμόζεται σχετικά καλά στα δεδομένα μου, καθώς οι δύο γραφικές παραστάσεις βρίσκονται πολύ κοντά η μία στην άλλη.

## Κατανομή LogNormal.

```
> modlnorm<-fit_data(data = cbdat, dist = "lnorm", time = "t",
  censor = "censor")
> summary(modlnorm)
Fitting of the distribution ' lnorm ' By maximum likelihood on
censored data
Parameters
      estimate Std. Error
meanlog 7.2692490 0.11176661
sdlog    0.4901095 0.08706352
Loglikelihood: -136.5736  AIC:  277.1472  BIC:  279.1387
Correlation matrix:
      meanlog      sdlog
meanlog 1.00000000 0.08798363
sdlog    0.08798363 1.00000000
```

### Συμπέρασμα :

#### 1. Παράμετροι Κατανομής log-normal:

Η εκτιμηθείσα τιμή του μέσου (meanlog) είναι περίπου 7.2692490, που αντιπροσωπεύει το μέσο λογαριθμικό της κατανομής log-normal.

Η εκτιμηθείσα τιμή του τυπικού αποκλίνοντος (sdlog) είναι περίπου 0.4901095, που αντιπροσωπεύει το πρότυπο απόκλισης της κατανομής log-normal.

#### 2. Στατιστικά Κριτήρια:

Η λογαριθμική πιθανοφάνεια (Loglikelihood) για το μοντέλο είναι περίπου -136.5736.

Το AIC είναι περίπου 277.1472.

Το BIC είναι περίπου 279.1387.

#### 3. Συσχέτιση Παραμέτρων:

Η συσχέτιση μεταξύ των παραμέτρων meanlog και sdlog είναι περίπου 0.08798363. Αυτό υποδεικνύει το επίπεδο της συσχέτισης μεταξύ των δύο παραμέτρων.

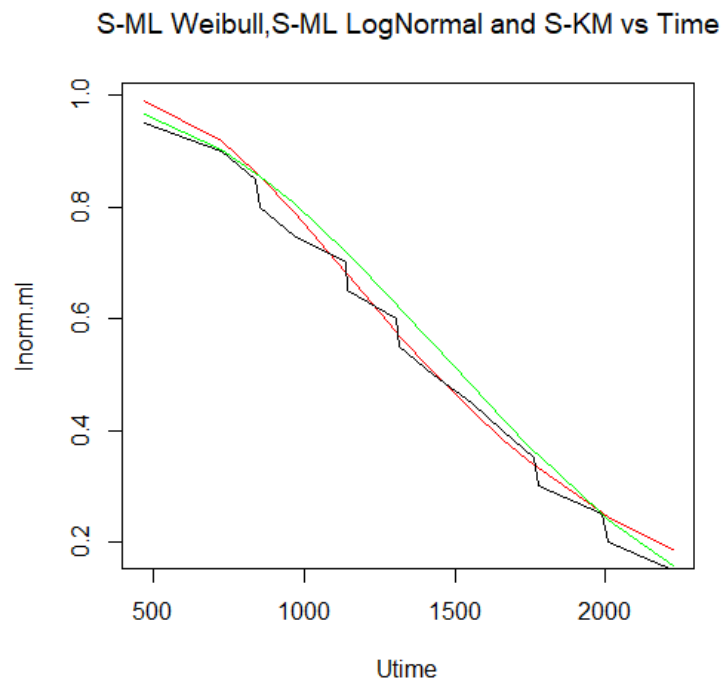
Συνολικά, τα αποτελέσματα αυτά δείχνουν ότι η κατανομή log-normal προσαρμόζεται καλά στα δεδομένα σας, με τις εκτιμηθείσες παραμέτρους να παρέχουν μια καλή περιγραφή της καμπύλης επιβίωσης.

```
> lnorm.ml<-plnorm(Utime, meanlog=modlnorm$estimate[1] , sdlog =
  modlnorm$estimate[2] ,
+ lower.tail = FALSE, log.p = FALSE)
> lnorm.ml
[1] 0.9888962 0.9182995 0.8639382 0.8558790 0.7911074 0.6815449
0.6796271
[8] 0.5776916 0.5697553 0.5048182 0.4357005 0.3843586 0.3370607
0.3320239
[15] 0.2525569 0.2460827 0.1858489
>
>
```

```

> plot(lnorm.ml~Utime,type="l",col="red",
main=expression(paste("S-ML Weibull,S-ML LogNormal and S-KM vs
Time"))))
> lines(SKM~Utime,col="black")
> lines(Weibml~Utime,col="green")

```



#### Παρατηρήσεις:

Στο παραπάνω σχήμα τώρα έχουμε στο ίδιο σύστημα αξόνων με μαύρο χρώμα τις εκτιμήσεις από την Μέθοδο Μεγίστης Πιθανοφάνειας, με κόκκινο χρώμα το μοντέλο της κατανομής LogNormal. Και πράσινο χρώμα το μοντέλο της κατανομής Weibull. Σύμφωνα με το σχήμα λοιπόν, το μοντέλο της κατανομής LogNormal προσαρμόζεται πολύ καλά στις εκτιμήσεις μου, ακόμη καλύτερα από το μοντέλο της κατανομής Weibull.

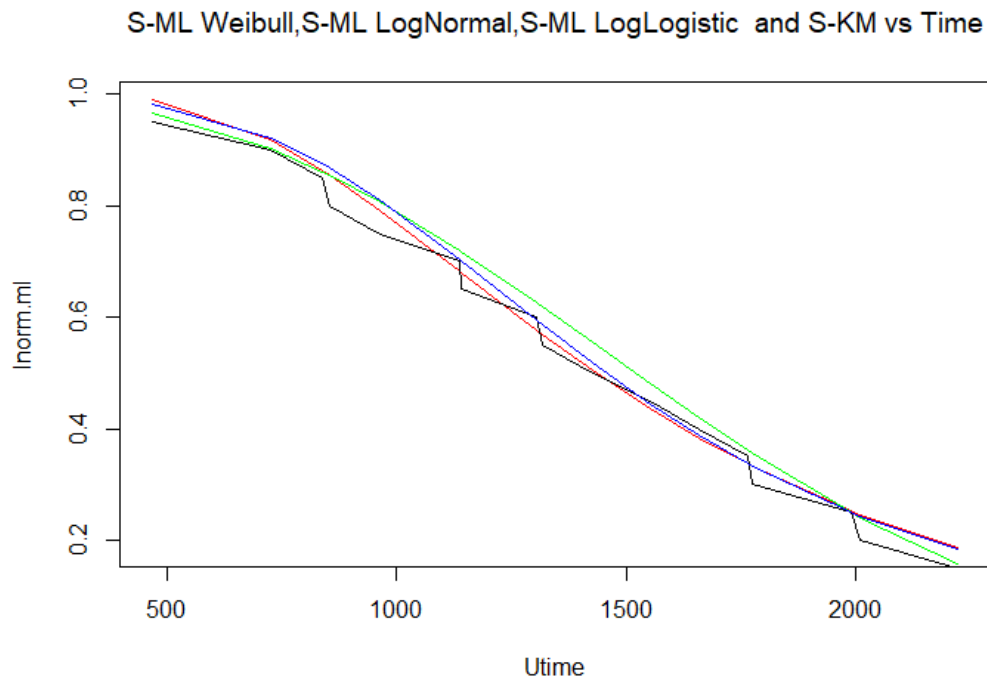
## Κατανομή LogLogistic.

```
> library(actuar)
> mod.log.logis<-fit_data(data = cbdat, dist = "llogis",    time
= "t",    censor = "censor")
> summary(mod.log.logis)
Fitting of the distribution ' llogis ' By maximum likelihood on
censored data
Parameters
      estimate Std. Error
shape      3.515627    0.707869
scale 1456.086237 161.513906
Loglikelihood: -136.6422    AIC: 277.2844    BIC: 279.2759
Correlation matrix:
      shape      scale
shape  1.0000000000 -0.001853006
scale -0.001853006  1.0000000000

> log.logis.ml <-pllogis(Utime, shape =
mod.log.logis$estimate[1], scale =
+ mod.log.logis$estimate[2], lower.tail = FALSE, log.p = FALSE)
> log.logis.ml
[1] 0.9818430 0.9206764 0.8746097 0.8676082 0.8094216 0.7033796
0.7014465
[8] 0.5957599 0.5873337 0.5177270 0.4430489 0.3878072 0.3375103
0.3322017
[15] 0.2500735 0.2435385 0.1840625

> plot(lnorm.ml~Utime,type="l", col="red",
main=expression(paste("S-ML Weibull,S-ML LogNormal,S-ML
LogLogistic and S-KM vs Time")))
> lines(SKM~Utime,col="black")
> lines(Weibml~Utime,col="green")
> lines(log.logis.ml~Utime,col="blue")
```





#### Παρατηρήσεις:

Στο παραπάνω σχήμα τώρα έχουμε στο ίδιο σύστημα αξόνων με μαύρο χρώμα τις εκτιμήσεις από την Μέθοδο Μεγίστης Πιθανοφάνειας , με κόκκινο χρώμα το μοντέλο της κατανομής LogNormal, με πράσινο χρώμα το μοντέλο της κατανομής Weibull και με μπλε χρώμα το μοντέλο της κατανομής LogLogistic Σύμφωνα με το σχήμα λοιπόν , το μοντέλο της κατανομής LogLogistic προσαρμόζεται πολύ καλά στις εκτιμήσεις μου , ακόμη καλύτερα από το μοντέλο της κατανομής Weibull. Ωστόσο το μοντέλο της κατανομής LogNormal φαίνεται να είναι το καλύτερο .

iv. **Να γίνει ο έλεγχος Anderson–Darling για κάθε μια από αυτές τις κατανομές και να εφαρμοστεί το κριτήριο AIC.**

Σε αυτόν τον έλεγχο θα συγκρίνω τα αποτελέσματα του Anderson-Darling Test και του AIC Test για τις κατανομες Weibull, Log Normal και Log Logistic.

Δεν θα κάνω κάποια σύγκριση με την Exponential, καθώς τα αποτελέσματα της για την προσαρμογή της με `parmsurvfit` δεν είναι πολύ καλά. Άλλωστε στα προηγούμενα ερωτήματα απέρριψα το μοντέλο της, δηλαδή τα δεδομένα μου αποκλείεται να ακολουθούν το μοντέλο της Εκθετικής.

```
> compute_AD (data = cdat, dist = "weibull", time = "t",  
  censor = "censor")  
[1] 13.78981  
> compute_AD (data = cdat, dist = "lnorm", time = "t",  
  censor = "censor")  
[1] 13.83252  
> compute_AD (data = cdat, dist = "llogis", time = "t",  
  censor = "censor")  
[1] 13.80438
```

	AD	AIC
Weibull	13.78981	277.2924
LogNormal	13.83252	277.1472
LogLogistic	13.80438	277.2844

#### Παρατηρήσεις:

Μια μικρή τιμή του AD τεστ υποδηλώνει ότι τα δεδομένα σας πιθανότατα προέρχονται από την κατανομή που ελέγχεται, ενώ μια μεγαλύτερη τιμή υποδηλώνει μεγαλύτερες αποκλίσεις από αυτήν την κατανομή.

Με βάση τις τιμές που παρέχονται, φαίνεται ότι η Weibull κατανομή έχει το χαμηλότερο Anderson-Darling τεστ, οπότε θα μπορούσε να είναι η πλέον κατάλληλη για τα δεδομένα σας. Ωστόσο, οι αποκλίσεις από τη Weibull κατανομή είναι ελάχιστες μεταξύ των τριών επιλογών, οπότε ενδέχεται να απαιτούνται περαιτέρω εξέταση.

Το κριτήριο του Πληροφοριακού Κριτηρίου (AIC) χρησιμοποιείται για τη σύγκριση των μοντέλων, με μικρότερες τιμές να υποδεικνύουν καλύτερη προσαρμογή των δεδομένων. Από τις παρεχόμενες τιμές AIC, φαίνεται ότι η Log-Normal κατανομή έχει τη μικρότερη τιμή AIC (277.1472), ενώ η Weibull και η Log-Logistic έχουν τιμές AIC 277.2924 και 277.2844 αντίστοιχα. Ωστόσο, η διαφορά μεταξύ των τιμών AIC είναι μικρή, οπότε πρέπει να ληφθούν υπόψη και άλλοι παράγοντες κατά τη λήψη αποφάσεων για την κατάλληλη κατανομή.

- v. Να γίνει ο στατιστικός έλεγχος υποθέσεων της Εκθετικής κατανομής ( $\eta = 1$ ) με εναλλακτική την κατανομή Weibull ( $\eta \neq 1$ ) (μπορείτε να αξιοποιήσετε και ένα 0.95 Δ.Ε. για την παράμετρο  $\eta$  της κατανομής Weibull). Τι συμπεραίνετε;

### Wald Test

Κάνει ένα τεστ και ελέγχει αν ο λογάριθμος του  $\alpha$  είναι 0 ή όχι, δηλαδή κάνει ένα τεστ για να δει εάν τα δεδομένα μας προσαρμόζονται καλύτερα στο μοντέλο της Εκθετικής Κατανομής ή στο μοντέλο της Κατανομής Weibull.

```
> summary(mod1)
```

Call:

```
survreg(formula = Surv(t, censor) ~ 1, data = cbdat, dist =  
"exponential")
```

	Value	Std. Error	z	p
(Intercept)	<b>7.475</b>	0.243	30.8	<b>&lt;2e-16</b>

Scale fixed at 1

Exponential distribution

Loglik(model)= -144.1    Loglik(intercept only)= -144.1

Number of Newton-Raphson Iterations: 3

n= 20

### Συμπέρασμα :

Το p-value είναι πολύ μικρό , άρα απορρίπτω την μηδενική υπόθεση. Άρα συμπεραίνω ότι τα δεδομένα ακολουθούν καλύτερα το μοντέλο της Weibull και όχι της Εκθετικής.

(C) Τα δεδομένα στο αρχείο «lung-patients.txt» αφορούν τη διάρκεια παροχής οξυγόνου (σε ημέρες) σε 78 ασθενείς με αναπνευστικά προβλήματα που νοσηλεύτηκαν σε κλινική για ένα συγκεκριμένο διάστημα. Η μία ομάδα των 43 ασθενών υποβλήθηκε σε ενισχυμένη θεραπεία πνεύμονα (=0), ενώ οι υπόλοιποι 35 όχι (=1).

Ξεκινάω με εισαγωγή των δεδομένων στην R .

```
> library(splines)
> library(survival)
> cc <- read.table("C:\\Users\\Admin\\Desktop\\8o ΕΞΑΜΗΜΟ\\lung-
patients.txt", header = TRUE)
> attach(cc)
```

The following objects are masked from cbindat (pos = 4):

c, Group, id, t

The following object is masked from cbindat (pos = 5):

t

The following object is masked from cbindat (pos = 7):

t

The following object is masked from cbindat (pos = 8):

t

```
> cc
  id Group    t c
1   1     0  59 1
2   2     0 514 1
3   3     0 313 1
4   4     0 631 1
5   5     0 107 1
6   6     0  71 1
7   7     0 583 1
8   8     0  91 1
9   9     0  66 1
10 10     0  95 1
11 11     0  13 1
12 12     0   5 1
13 13     0  85 1
14 14     0 619 0
15 15     0 580 1
16 16     0 196 1
17 17     0 475 1
18 18     0  32 1
19 19     0 161 1
20 20     0 193 0
21 21     0  59 1
22 22     0  62 1
23 23     0  95 1
24 24     0  63 1
25 25     0  26 1
```

26	26	0	16	1
27	27	0	553	1
28	28	0	76	1
29	29	0	134	1
30	30	0	116	1
31	31	0	83	1
32	32	0	33	1
33	33	0	317	1
34	34	0	600	1
35	35	0	362	1
36	36	0	333	1
37	37	0	68	1
38	38	0	217	1
39	39	0	733	0
40	40	0	546	1
41	41	0	546	1
42	42	0	56	1
43	43	0	48	1
44	44	1	43	1
45	45	1	250	1
46	46	1	110	1
47	47	1	249	1
48	48	1	181	1
49	49	1	70	1
50	50	1	197	1
51	51	1	306	1
52	52	1	53	1
53	53	1	30	1
54	54	1	45	1
55	55	1	23	1
56	56	1	54	1
57	57	1	63	1
58	58	1	14	1
59	59	1	96	1
60	60	1	103	1
61	61	1	71	1
62	62	1	71	1
63	63	1	64	1
64	64	1	253	1
65	65	1	54	1
66	66	1	236	1
67	67	1	51	1
68	68	1	134	1
69	69	1	31	1
70	70	1	274	0
71	71	1	204	1
72	72	1	118	1
73	73	1	424	1
74	74	1	56	1
75	75	1	310	0
76	76	1	108	1
77	77	1	51	1
78	78	1	70	1

>

- i. **Να υπολογιστούν οι εκτιμήτριες Kaplan–Meier και να γίνουν οι γραφικές παραστάσεις αυτών για τις δύο ομάδες.**

Στο ερώτημα αυτό θα υπολογίσω τις εκτιμήσεις μέσω της μη παραμετρική μεθόδου Kaplan Meier .

```
> outp<-survfit(Surv(t,c)~Group)
```

```
> summary(outp)
```

```
Call: survfit(formula = Surv(t, c) ~ Group)
```

```

              Group=0
time n.risk n.event survival std.err lower 95% CI upper 95% CI
  5      43        1  0.9767  0.0230    0.93272    1.000
 13      42        1  0.9535  0.0321    0.89258    1.000
 16      41        1  0.9302  0.0388    0.85712    1.000
 26      40        1  0.9070  0.0443    0.82418    0.998
 32      39        1  0.8837  0.0489    0.79292    0.985
 33      38        1  0.8605  0.0528    0.76289    0.971
 48      37        1  0.8372  0.0563    0.73383    0.955
 56      36        1  0.8140  0.0593    0.70557    0.939
 59      35        2  0.7674  0.0644    0.65101    0.905
 62      33        1  0.7442  0.0665    0.62456    0.887
 63      32        1  0.7209  0.0684    0.59859    0.868
 66      31        1  0.6977  0.0700    0.57306    0.849
 68      30        1  0.6744  0.0715    0.54795    0.830
 71      29        1  0.6512  0.0727    0.52322    0.810
 76      28        1  0.6279  0.0737    0.49885    0.790
 83      27        1  0.6047  0.0746    0.47483    0.770
 85      26        1  0.5814  0.0752    0.45116    0.749
 91      25        1  0.5581  0.0757    0.42781    0.728
 95      24        2  0.5116  0.0762    0.38206    0.685
107      22        1  0.4884  0.0762    0.35966    0.663
116      21        1  0.4651  0.0761    0.33757    0.641
134      20        1  0.4419  0.0757    0.31579    0.618
161      19        1  0.4186  0.0752    0.29432    0.595
196      17        1  0.3940  0.0747    0.27166    0.571
217      16        1  0.3694  0.0740    0.24940    0.547
313      15        1  0.3447  0.0731    0.22757    0.522
317      14        1  0.3201  0.0719    0.20616    0.497
333      13        1  0.2955  0.0704    0.18521    0.471
362      12        1  0.2709  0.0687    0.16473    0.445
475      11        1  0.2462  0.0667    0.14475    0.419
514      10        1  0.2216  0.0645    0.12532    0.392
546       9        2  0.1724  0.0588    0.08833    0.336
553       7        1  0.1477  0.0553    0.07093    0.308
580       6        1  0.1231  0.0513    0.05442    0.279
583       5        1  0.0985  0.0466    0.03900    0.249
600       4        1  0.0739  0.0409    0.02495    0.219
631       2        1  0.0369  0.0332    0.00635    0.215

```


Group=1							
time	n.risk	n.event	survival	std.err	lower 95% CI	upper 95% CI	
14	35	1	0.9714	0.0282	0.9178	1.000	
23	34	1	0.9429	0.0392	0.8690	1.000	
30	33	1	0.9143	0.0473	0.8261	1.000	
31	32	1	0.8857	0.0538	0.7863	0.998	
43	31	1	0.8571	0.0591	0.7487	0.981	
45	30	1	0.8286	0.0637	0.7127	0.963	
51	29	2	0.7714	0.0710	0.6441	0.924	
53	27	1	0.7429	0.0739	0.6113	0.903	
54	26	2	0.6857	0.0785	0.5479	0.858	
56	24	1	0.6571	0.0802	0.5173	0.835	
63	23	1	0.6286	0.0817	0.4873	0.811	
64	22	1	0.6000	0.0828	0.4578	0.786	
70	21	2	0.5429	0.0842	0.4005	0.736	
71	19	2	0.4857	0.0845	0.3454	0.683	
96	17	1	0.4571	0.0842	0.3186	0.656	
103	16	1	0.4286	0.0836	0.2923	0.628	
108	15	1	0.4000	0.0828	0.2666	0.600	
110	14	1	0.3714	0.0817	0.2414	0.572	
118	13	1	0.3429	0.0802	0.2167	0.542	
134	12	1	0.3143	0.0785	0.1927	0.513	
181	11	1	0.2857	0.0764	0.1692	0.482	
197	10	1	0.2571	0.0739	0.1464	0.452	
204	9	1	0.2286	0.0710	0.1244	0.420	
236	8	1	0.2000	0.0676	0.1031	0.388	
249	7	1	0.1714	0.0637	0.0827	0.355	
250	6	1	0.1429	0.0591	0.0635	0.322	
253	5	1	0.1143	0.0538	0.0454	0.287	
306	3	1	0.0762	0.0475	0.0225	0.258	
424	1	1	0.0000	NaN	NA	NA	

### Παρατηρήσεις:

Είναι φανερό ότι όσο περνάει ο χρόνος όλο και λιγότεροι επιβιώνουν .

Ύστερα θα κατασκευάσω την γραφική παράσταση των εκτιμήσεων της Kaplan – Meier .

```
> plot(outp, lty = 1:2, main=expression(paste("Kaplan-Meier-estimate ",
hat(S) (t))),
+ xlab="t", ylab="Survival", lwd=2)
> legend("topright", c("Group 0", "Group 1"), lty = 1:2)
>
```



#### Παρατηρήσεις:

Φαίνεται σύμφωνα με το παραπάνω γράφημα ότι οι ασθενείς από την πρώτη ομάδα (ομάδα =0) των ασθενών , δηλαδή από την ομάδα που υποβλήθηκε σε ενισχυμένη θεραπεία , επιβιώνουν περισσότερο , από τους ασθενείς που βρίσκονται στην δεύτερη ομάδα (ομάδα =1 ), οι οποίοι δεν υποβλήθηκαν σε ενισχυμένη θεραπεία.



ii. **Να γίνουν οι έλεγχοι log-rank και Wilcoxon για τη σύγκριση των δύο ομάδων ως προς τη διάρκεια παροχής οξυγόνου.**

```
> #Log-rank test (Mantel-Haenszel test) with R
> out1<-survdif(Surv(t, c) ~ Group)
> out1
Call:
survdif(formula = Surv(t, c) ~ Group)

      N Observed Expected (O-E)^2/E (O-E)^2/V
Group=0 43      40      48.9      1.64      5.62
Group=1 35      33      24.1      3.33      5.62

Chisq= 5.6  on 1 degrees of freedom, p= 0.02
>
```

**Παρατηρήσεις:**

Η συνολική στατιστική τιμή  $\chi^2$ -τετραγωνικού είναι 5.6 με 1 βαθμό ελευθερίας και η p-τιμή είναι 0.02. Αυτό υποδεικνύει ότι υπάρχει στατιστικά σημαντική διαφορά μεταξύ των επιβιώσεων των δύο ομάδων στο επίπεδο εμπιστοσύνης του 95%, καθώς η p-τιμή είναι μικρότερη από το επίπεδο αποκοπής 0.05.

- iii. Κάνοντας χρήση των εκτιμήσεων Kaplan–Meier να γίνουν γραφικοί έλεγχοι των κατανομών Weibull και Λογαριθμο–λογιστικής για τις δύο ομάδες χωριστά. Ενισχύστε τα συμπεράσματά σας με το κριτήριο AIC.

[https://helios.ntua.gr/pluginfile.php/264283/mod\\_resource/content/3/Hodgins1-%20parametric%20results-weibull%20and%20loglogistic.pdf](https://helios.ntua.gr/pluginfile.php/264283/mod_resource/content/3/Hodgins1-%20parametric%20results-weibull%20and%20loglogistic.pdf)

```
> library(survival)
> library(parmsurvfit)
```

### Parametric Results for 1<sup>st</sup> group

```
> group0<- Surv(t[Group=="0"],c[Group=="0"])
> outp0<-survfit(group0~1, type="kaplan-meier",data=cc)
> summary(outp0)
Call: survfit(formula = group0 ~ 1, data = cc, type = "kaplan-meier")
```

time	n.risk	n.event	survival	std.err	lower 95% CI	upper 95% CI
5	43	1	0.9767	0.0230	0.93272	1.000
13	42	1	0.9535	0.0321	0.89258	1.000
16	41	1	0.9302	0.0388	0.85712	1.000
26	40	1	0.9070	0.0443	0.82418	0.998
32	39	1	0.8837	0.0489	0.79292	0.985
33	38	1	0.8605	0.0528	0.76289	0.971
48	37	1	0.8372	0.0563	0.73383	0.955
56	36	1	0.8140	0.0593	0.70557	0.939
59	35	2	0.7674	0.0644	0.65101	0.905
62	33	1	0.7442	0.0665	0.62456	0.887
63	32	1	0.7209	0.0684	0.59859	0.868
66	31	1	0.6977	0.0700	0.57306	0.849
68	30	1	0.6744	0.0715	0.54795	0.830
71	29	1	0.6512	0.0727	0.52322	0.810
76	28	1	0.6279	0.0737	0.49885	0.790
83	27	1	0.6047	0.0746	0.47483	0.770
85	26	1	0.5814	0.0752	0.45116	0.749
91	25	1	0.5581	0.0757	0.42781	0.728
95	24	2	0.5116	0.0762	0.38206	0.685
107	22	1	0.4884	0.0762	0.35966	0.663
116	21	1	0.4651	0.0761	0.33757	0.641
134	20	1	0.4419	0.0757	0.31579	0.618
161	19	1	0.4186	0.0752	0.29432	0.595
196	17	1	0.3940	0.0747	0.27166	0.571
217	16	1	0.3694	0.0740	0.24940	0.547
313	15	1	0.3447	0.0731	0.22757	0.522
317	14	1	0.3201	0.0719	0.20616	0.497
333	13	1	0.2955	0.0704	0.18521	0.471
362	12	1	0.2709	0.0687	0.16473	0.445
475	11	1	0.2462	0.0667	0.14475	0.419
514	10	1	0.2216	0.0645	0.12532	0.392
546	9	2	0.1724	0.0588	0.08833	0.336
553	7	1	0.1477	0.0553	0.07093	0.308
580	6	1	0.1231	0.0513	0.05442	0.279
583	5	1	0.0985	0.0466	0.03900	0.249
600	4	1	0.0739	0.0409	0.02495	0.219
631	2	1	0.0369	0.0332	0.00635	0.215

### **Split data into two groups**

```
> ccdat0 <- subset(cc, Group ==0)
> ccdat1 <-subset(cc, Group ==1)
```

## Fitting Weibull distribution


```
> modweib0<-fit_data(data = ccdat0, dist = "weibull", time = "t", censor
= "c")
> summary(modweib0)
Fitting of the distribution ' weibull ' By maximum likelihood on censored
data
Parameters
      estimate Std. Error
shape  0.9338227  0.1179091
scale 244.8090140 42.8450786
Loglikelihood: -260.8308  AIC: 525.6616  BIC: 529.184
Correlation matrix:
      shape      scale
shape 1.0000000 0.2515068
scale 0.2515068 1.0000000

> SWeib.ml0<- pweibull(Utime0, shape= modweib0$estimate[1], scale =
+ modweib0$estimate[2], lower.tail = FALSE, log.p = FALSE)
> SWeib.ml0
 [1] 0.97392358 0.93754661 0.92469838 0.88409127 0.86109077 0.85734471
 [7] 0.80380897 0.77708419 0.75778601 0.75462870 0.74525487 0.73908593
[13] 0.72995014 0.71502875 0.69475369 0.68908785 0.67241664 0.63022242
[19] 0.60783752 0.56573128 0.50857139 0.44375052 0.40921817 0.28424327
[25] 0.28000988 0.26373012 0.23671066 0.15613762 0.13546767 0.11761777
[31] 0.10669888 0.10555202 0.09928900 0.08883526

> plot_ppsurv(ccdat0, "weibull", time = "t", censor = "c")
```

### Συμπέρασμα :

Σύμφωνα με το διαγγραμμα στα δεξιά, λόγω δεν παρατηρώ κάποια τάυτιση των αποτελεσμάτων (εκτιμησεων KM) με την ευθεία έχω αρκετές ενδείξεις ώστε να απορριψω την υποθήση, ότι τα δεδομένα της πρώτης ομάδας ακολουθούν το μοντέλο της Weibull Κατανομή.



## Fitting Log-logistic distribution


```
> library(actuar)
>
> modllog0<-fit_data(data = ccdat0, dist = "llogis", time = "t", censor =
"c")
> summary(modllog0)
Fitting of the distribution ' llogis ' By maximum likelihood on censored
data
Parameters
      estimate Std. Error
shape    1.341917   0.1729928
scale 138.446997  27.8095493
Loglikelihood:  -261.1803   AIC:  526.3605   BIC:  529.8829
Correlation matrix:
      shape      scale
shape  1.00000000 -0.02933534
scale -0.02933534  1.00000000

> Sllogis.ml0<-pllogis(Utime0, shape = modllog0$estimate[1], scale =
+ modllog0$estimate[2], lower.tail = FALSE, log.p = FALSE)
> Sllogis.ml0
[1] 0.9885310 0.9598578 0.9476345 0.9041500 0.8771351 0.8726152 0.8055695
[8] 0.7711149 0.7461217 0.7420331 0.7299042 0.7219342 0.7101562 0.6910047
[15] 0.6652075 0.6580544 0.6371709 0.5855882 0.5590683 0.5109509
0.4495429
[22] 0.3854481 0.3536415 0.2507488 0.2475609 0.2354587 0.2158879
0.1605216
[29] 0.1467602 0.1348918 0.1275996 0.1268310 0.1226207 0.1155314


> plot_ppsurv(ccdat0, "llogis", time = "t", censor = "c")
```

### Συμπέρασμα :

Σύμφωνα με το διαγγραμμα στα δεξιά, λόγω δεν παρατηρώ κάποια τάυτιση των αποτελεσμάτων (εκτιμησεων KM) με την ευθεία έχω αρκετές ενδείξεις ώστε να απορρίψω την υποθήση , ότι τα δεδομένα της πρώτης ομάδας ακολουθούν το μοντέλο της **Log-logistic** Κατανομή.



```
> plot(SKM0~ Utime0,type="l", col="black", main=expression(paste("Group 0
-
+ Estimated Survival Functions vs Time")), xlab="Time", ylab="S(t)")
> lines(SWeib.ml0~ Utime0,col="green", lwd=2)
> lines(Sllogis.ml0~ Utime0,col="blue", lwd=2)
> legend("topright", c("S-KM", "Sweib", "Sllogis"), col=c("black",
"green","blue"), lty=c(1,2,3) )
```



### Συμπέρασμα :

Στο παραπάνω σχήμα η μαύρη καμπύλη παρουσιάζει την εκτίμηση μέσω της Kaplan – Meier , η πράσινη καμπύλη παρουσιάζει το μοντέλο της κατανομής Weibull και η μπλέ καμπύλη παρουσιάζει το μοντέλο της κατανομής Log-logistic για τα δεδομένα της 1ης ομάδας (Group = 0).

Είναι φανερό στο παραπάνω σχήμα ότι , κανένα από τα δύο μοντέλα κακόνομων δεν προσαρμόζεται καλά στα δεδομένα της 1ης ομάδας (Group = 0).

### **ΚΡΙΤΗΡΙΟ AIC**

1st Group (Group = 0)	
	AIC
Weibull Distribution	525.6616
Log-Logistic Distribution	526.3605

#### **Συμπέρασμα :**

Βασισμένο στα παραπάνω αποτελέσματα, φαίνεται ότι το μοντέλο Log-Logistic Distribution έχει μικρότερο AIC (526.3605) σε σύγκριση με το μοντέλο Weibull Distribution (525.6616) για την 1η ομάδα (Group = 0). Συνεπώς, το μοντέλο Log-Logistic φαίνεται να προσαρμόζεται καλύτερα στα δεδομένα της 1ης ομάδας, βάσει του κριτηρίου του AIC.

Ωστόσο το AIC είναι πολύ υψηλό και στις δύο περιπτώσεις, άρα συμπεραίνω ότι κανένα μοντέλο δεν είναι το ιδανικό για τα δεδομένα της 1ης ομάδας (Group = 0).

## Parametric Results for 2<sup>nd</sup> group

```
> group1<- Surv(t[Group=="1"],c[Group=="1"])
> outp1<-survfit(group1~1, type="kaplan-meier",data=cc)
> summary(outp1)
Call: survfit(formula = group1 ~ 1, data = cc, type = "kaplan-meier")
```

time	n.risk	n.event	survival	std.err	lower 95% CI	upper 95% CI
14	35	1	0.9714	0.0282	0.9178	1.000
23	34	1	0.9429	0.0392	0.8690	1.000
30	33	1	0.9143	0.0473	0.8261	1.000
31	32	1	0.8857	0.0538	0.7863	0.998
43	31	1	0.8571	0.0591	0.7487	0.981
45	30	1	0.8286	0.0637	0.7127	0.963
51	29	2	0.7714	0.0710	0.6441	0.924
53	27	1	0.7429	0.0739	0.6113	0.903
54	26	2	0.6857	0.0785	0.5479	0.858
56	24	1	0.6571	0.0802	0.5173	0.835
63	23	1	0.6286	0.0817	0.4873	0.811
64	22	1	0.6000	0.0828	0.4578	0.786
70	21	2	0.5429	0.0842	0.4005	0.736
71	19	2	0.4857	0.0845	0.3454	0.683
96	17	1	0.4571	0.0842	0.3186	0.656
103	16	1	0.4286	0.0836	0.2923	0.628
108	15	1	0.4000	0.0828	0.2666	0.600
110	14	1	0.3714	0.0817	0.2414	0.572
118	13	1	0.3429	0.0802	0.2167	0.542
134	12	1	0.3143	0.0785	0.1927	0.513
181	11	1	0.2857	0.0764	0.1692	0.482
197	10	1	0.2571	0.0739	0.1464	0.452
204	9	1	0.2286	0.0710	0.1244	0.420
236	8	1	0.2000	0.0676	0.1031	0.388
249	7	1	0.1714	0.0637	0.0827	0.355
250	6	1	0.1429	0.0591	0.0635	0.322
253	5	1	0.1143	0.0538	0.0454	0.287
306	3	1	0.0762	0.0475	0.0225	0.258
424	1	1	0.0000	NaN	NA	NA

>

```
> Utime1<- outp1$time[outp1$n.event==1]
> SKM1<-outp1$surv[outp1$n.event==1]
>
```



## Fitting Weibull distribution


```
> modweib1<-fit_data(data = ccdat1, dist = "weibull", time = "t", censor
="c")
> summary(modweib1)
Fitting of the distribution ' weibull ' By maximum likelihood on censored
data
Parameters
      estimate Std. Error
shape    1.259085   0.1699116
scale 143.685225  20.6333246
Loglikelihood:  -193.6603    AIC:  391.3207    BIC:  394.4314
Correlation matrix:
      shape      scale
shape 1.0000000  0.2698941
scale 0.2698941  1.0000000

> SWeib.ml1<- pweibull(Utime1, shape= modweib1$estimate[1], scale =
+ modweib1$estimate[2], lower.tail = FALSE, log.p = FALSE)
> SWeib.ml1
 [1] 0.94809789 0.90521889 0.87010516 0.86501719 0.80337595 0.79308092
 [7] 0.75211312 0.73688925 0.70178681 0.69682744 0.54780151 0.51808851
[13] 0.49755336 0.48950166 0.45822842 0.40016270 0.26254133 0.22585488
[19] 0.21124600 0.15446152 0.13557003 0.13420637 0.13018898 0.07498887
[25] 0.02012451

> plot_ppsurv(ccdat1, "weibull", time = "t", censor = "c")
>
```

### Συμπέρασμα :

Σύμφωνα με το διαγγραμμα στα δεξιά, λόγω δεν παρατηρώ κάποια τάυτιση των αποτελεσμάτων (εκτιμησεων KM) με την ευθεία έχω αρκετές ενδείξεις ώστε να απορρίψω την υποθήση , ότι τα δεδομένα της δεύτερης ομάδας ακολουθούν το μοντέλο της **Weibull** Κατανομή.



## Fitting Log-logistic distribution

```
> library(actuar)
```

Attaching package: 'actuar'

The following objects are masked from 'package:stats':

sd, var

The following object is masked from 'package:grDevices':

cm

```
> modllog1<-fit_data(data = ccdat1, dist = "llogis", time = "t", censor = "c")
```

```
> summary(modllog1)
```

Fitting of the distribution ' llogis ' By maximum likelihood on censored data

Parameters

	estimate	Std. Error
--	----------	------------

shape	1.953817	0.2782326
-------	----------	-----------

scale	92.627407	14.1293125
-------	-----------	------------

Loglikelihood:	-192.2891	AIC: 388.5781	BIC: 391.6888
----------------	-----------	---------------	---------------

Correlation matrix:

	shape	scale
--	-------	-------

shape	1.00000000	-0.05036393
-------	------------	-------------

scale	-0.05036393	1.00000000
-------	-------------	------------

```
> Sllogis.ml1<-pllogis(Utime1, shape = modllog1$estimate[1], scale =  
+ modllog1$estimate[2], lower.tail = FALSE, log.p = FALSE)
```

```
> Sllogis.ml1
```


[1]	0.97567897	0.93830343	0.90049257	0.89460285	0.81747453	0.80384556
[7]	0.74853287	0.72774788	0.67985370	0.67311993	0.48253845	0.44833857
[13]	0.42555721	0.41681743	0.38390210	0.32707238	0.21267338	0.18627673
[19]	0.17615661	0.13856008	0.12652196	0.12565906	0.12312069	0.08828061
[25]	0.04870484					

```
> plot_ppsurv(ccdat1, "llogis", time = "t", censor = "c")
```


```
>
```

### Συμπέρασμα :

Σύμφωνα με το διαγραμμα στα δεξιά, λόγω δεν παρατηρώ κάποια τάυση των αποτελεσμάτων (εκτιμησεων KM) με την ευθεία έχω αρκετές ενδείξεις ώστε να απορρίψω την υποθεση, ότι τα δεδομένα της δεύτερης ομάδας ακολουθούν το μοντέλο της **Log-logistic** Κατανομή.



```
> plot(SKM1~ Utime1,type="l", col="black", main=expression(paste("Group 1
(NHL) -
+ Estimated Survival Functions vs Time")), xlab="Time", ylab="S(t)")
> lines(SWeib.m11~ Utime1,col="green", lwd=2)
> lines(Sllogis.m11~ Utime1,col="blue", lwd=2)
> legend("topright", c("S-KM", "Sweib", "Sllogis"), col=c("black",
"green","blue"), lty=c(1,2,3) )
>
```



### **Συμπέρασμα :**

Στο παραπάνω σχήμα η μαύρη καμπύλη παρουσιάζει την εκτίμηση μέσω της Kaplan – Meier , η πράσινη καμπύλη παρουσιάζει το μοντέλο της κατανομής Weibull και η μπλέ καμπύλη παρουσιάζει το μοντέλο της κατανομής Log-logistic για τα δεδομένα της 2ης ομάδας (Group = 1).

Είναι φανερό στο παραπάνω σχήμα ότι , το μοντέλο της κατανομής Log-logistic προσαρμόζεται πολύ καλά στα δεδομένα της 1ης ομάδας (Group = 0), καλύτερα από το μοντέλο της κατανομής Weibull .

### **ΚΡΙΤΗΡΙΟ AIC**

2nd Group (Group = 1)	
	AIC
Weibull Distribution	391.3207
Log-Logistic Distribution	388.5781

#### **Συμπέρασμα :**

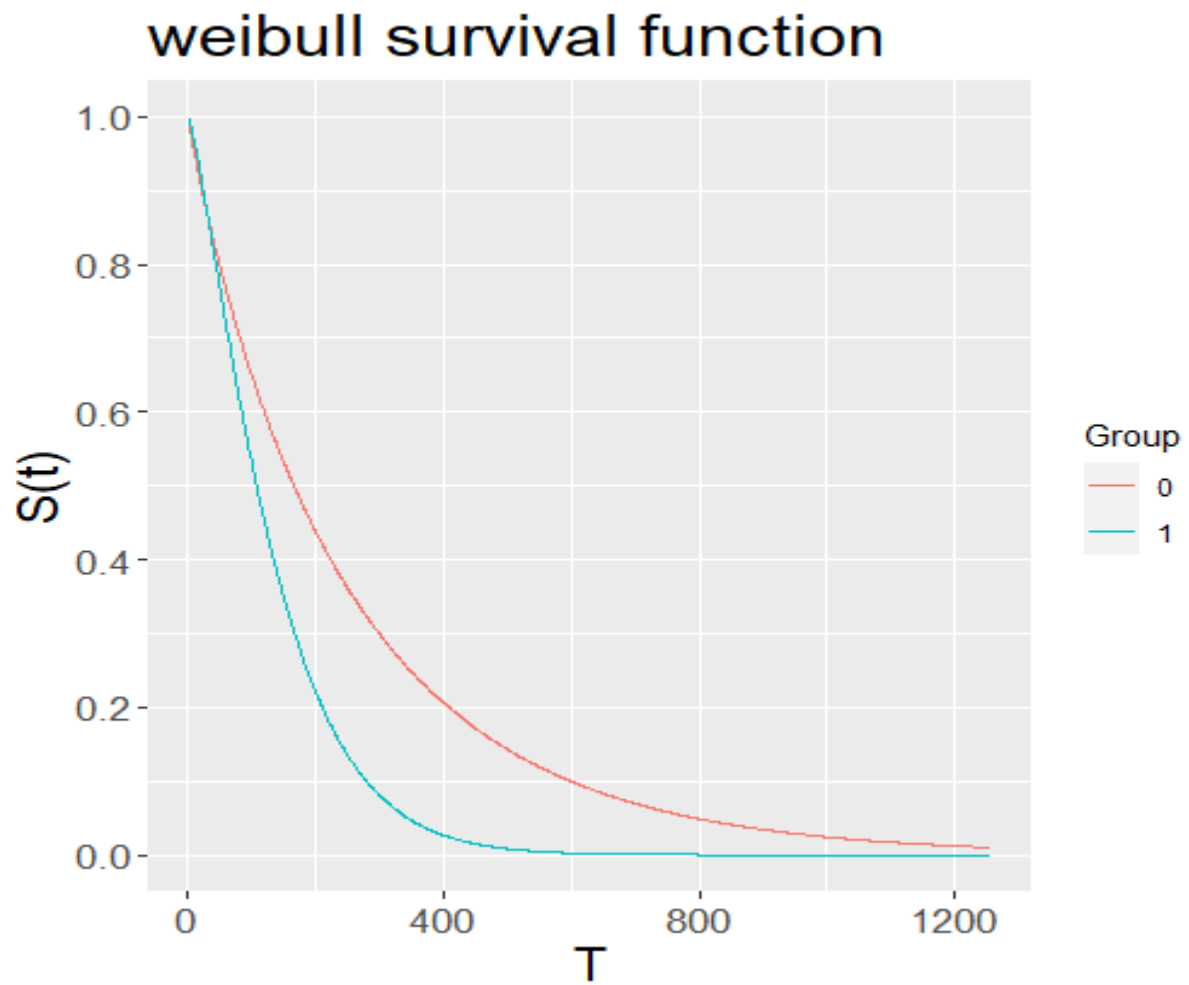
Οι δύο κατανομές (Weibull και Log-Logistic) προσαρμόζονται στα δεδομένα της 2ης ομάδας (Group = 1), με βάση το κριτήριο του AIC.

Το μικρότερο AIC υποδεικνύει καλύτερη προσαρμογή του μοντέλου στα δεδομένα. Συνεπώς, από τα παραπάνω αποτελέσματα, φαίνεται ότι το μοντέλο Log-Logistic Distribution έχει μικρότερη τιμή AIC (388.5781) σε σύγκριση με το μοντέλο Weibull Distribution (391.3207).

Συνεπώς, μπορούμε να συμπεράνουμε ότι το μοντέλο Log-Logistic Distribution προσαρμόζεται καλύτερα στα δεδομένα της 2ης ομάδας σε σχέση με το μοντέλο Weibull Distribution, βάσει του κριτηρίου του AIC.

```
> plot_surv(cc, "weibull", time = "t", censor = "c", by = "Group")
```

Μεθοδος μεγιστης πιθανοφανειας



- iv. Αν θεωρήσουμε ότι το μοντέλο της Λογαριθμο-λογιστικής κατανομής ταιριάζει στα δεδομένα μας, βρείτε για κάθε ομάδα ασθενών, τις ε.μ.π. των παραμέτρων του μοντέλου αυτού και ακολούθως την ε.μ.π. της διαμέσου χωριστά για τις δύο ομάδες. Με βάση τα αποτελέσματα αυτά, να κριθεί ποιά ομάδα αργεί περισσότερο να αποσυνδεθεί από το οξυγόνο.

Με αυτήν την παραμέτρηση

$$f(t) = \frac{\gamma \left(\frac{t}{\theta}\right)^\gamma}{t \left[1 + \left(\frac{t}{\theta}\right)^\gamma\right]^2}, t > 0, \gamma > 0, \theta > 0,$$

$$S(t) = \left[1 + \left(\frac{t}{\theta}\right)^\gamma\right]^{-1}$$

Shape=  $\gamma=1/\tau$   
scale=  $\theta=\exp(v)$

**Ομάδα =0**

```
> modllog0<-fit_data(data = ccdat0, dist = "llogis", time = "t", censor = "c")
> summary(modllog0)
Fitting of the distribution ' llogis ' By maximum likelihood on censored data
Parameters
      estimate Std. Error
shape    1.341917   0.1729928
scale   138.446997  27.8095493
Loglikelihood: -261.1803    AIC:  526.3605    BIC:  529.8829
Correlation matrix:
      shape      scale
shape  1.00000000 -0.02933534
scale -0.02933534  1.00000000
```

**ΕΜΠ:**

Shape=  $\gamma=1/\tau=1.341917$   
scale=  $\theta=\exp(v)=138.446997$

$$f(t) = \frac{1.341917 \left(\frac{t}{138.446997}\right)^{1.341917}}{t \left[1 + \left(\frac{t}{138.446997}\right)^{1.341917}\right]^2}$$

$$S(t) = \left[1 + \left(\frac{t}{138.446997}\right)^{1.341917}\right]^{-1}$$

**Διαμεσος :**

$$S(L_{50}) = \left[ 1 + \left( \frac{x}{138.446997} \right)^{1.341917} \right]^{-1} = 0.5 \Leftrightarrow L_{50} = 138.446997$$

**Ομάδα =1**

```
> modllog1<-fit_data(data = ccdat1, dist = "llogis", time = "t", censor =  
"c")  
> summary(modllog1)  
Fitting of the distribution ' llogis ' By maximum likelihood on censored  
data  
Parameters  
      estimate Std. Error  
shape  1.953817   0.2782326  
scale  92.627407  14.1293125  
Loglikelihood:  -192.2891   AIC:  388.5781   BIC:  391.6888  
Correlation matrix:  
      shape      scale  
shape  1.00000000 -0.05036393  
scale -0.05036393  1.00000000
```

**ΕΜΠ:**

Shape=  $\gamma=1/\tau=1.953817$   
scale= $\theta=\exp(v)=92.627407$

$$f(t) = \frac{1.953817 \left( \frac{t}{92.627407} \right)^{1.953817}}{t \left[ 1 + \left( \frac{t}{92.627407} \right)^{1.953817} \right]^2}$$
$$S(t) = \left[ 1 + \left( \frac{t}{92.627407} \right)^{1.953817} \right]^{-1}$$

**Διαμεσος :**

$$S(L_{50}) = \left[ 1 + \left( \frac{L_{50}}{92.627407} \right)^{1.953817} \right]^{-1} = 0.5 \Leftrightarrow L_{50} = 92.627407$$